

Resumen de hallazgos

Entregable 2 · Grupo M01 «El Factor D10S» · Abandono escolar en la educación secundaria

Mentora: Noelia Ferrero · Diplomatura en Ciencia de Datos, FAMAf (UNC)
Fuentes: Aprender 2024 (base agregada, Secretaría de Educación) y EPH 3er trimestre 2025 (INDEC)
Código, datos y documentación: github.com/IVillanueva770/factor-d10s-m01

1. ¿Qué encontramos en los datos?

El dataset maestro tiene **1.174 filas y 131 columnas**, y cada fila es un grupo (jurisdicción x departamento x sector x ámbito), no un estudiante. Detrás de esas filas hay **540.040 estudiantes** de Aprender 2024, y cada fila lleva una columna de peso que dice cuántos representa. Por eso ponderamos todo promedio de este informe por cantidad de estudiantes: un promedio simple hablaría de departamentos y no de chicos.

Seguimos **CRISP-DM**: el entregable 1 cubrió el entendimiento del negocio y de los datos, y este completa la preparación de los datos. El reencuadre que trajo la devolución del entregable 1, pasar de un modelo individual a uno ecológico sobre agregados territoriales, es una vuelta atrás de las que el método prevé, y la tomamos: todo lo que sigue habla de grupos y nunca de estudiantes. En lo operativo trabajamos con un pipeline por etapas con contrato explícito de entradas y salidas, 55 verificaciones automáticas sobre los datos y dos corridas seguidas que dan 18 de 18 salidas idénticas byte a byte.

De las 131 columnas, 85 son proporciones, 16 son coberturas que dicen qué fracción de la fila quedó representada en cada bloque de preguntas, 16 son indicadores de la EPH iguales para toda la provincia, 8 están armonizadas entre Aprender y la EPH, 4 identifican la fila, 1 es el peso y 1 es una bandera de control.

El hallazgo principal se entiende sin mirar una tabla

Dentro del mismo ámbito urbano, cambiar de sector de gestión mueve el desempeño **0,23 puntos**: 0,62 de los estudiantes de estatal urbana quedan por debajo del nivel básico en matemática contra 0,38 en privada urbana. Cambiar de ámbito dentro del sector privado lo mueve 0,13 (0,38 urbano contra 0,51 rural). **El sector pesa más que el lugar**. Apoyamos el titular a propósito en las dos celdas urbanas, porque entre las dos suman 504.759 estudiantes, el 93,5% del total.

En sobreedad alta la brecha va en el mismo sentido: 0,0285 en estatal rural contra 0,0062 en privado urbano, **4,6 veces mayor**. Un dato de color, con su denominador: un estudiante de estatal urbana (0,62) está peor que uno de privada rural (0,51), o sea que el campo no es lo que lo hunde; pero privada rural son 36 filas y 3.679 estudiantes, el 0,7% del total, y es la celda con mayor dispersión, así que ilustra y no sostiene. Lo que sugiere el conjunto es que la variable a mirar no es dónde queda la escuela sino quién la gestiona, y eso es una pregunta de política pública, no de geografía.




Figura 1. Desempeño bajo en matemática por sector y ámbito, ponderado por estudiantes. El panel derecho muestra cuánta gente hay detrás de cada barra: sin ese panel, la celda privada rural (0,7% de los estudiantes) parece igual de sólida que la estatal urbana (60,7%).

2. ¿Qué problemas de calidad detectamos?

Corrimos **doce chequeos** sobre el dataset y reportamos cada uno con su denominador. **Ocho dieron limpio y cuatro encontraron algo**. Esta etapa mide y no corrige: la corrección la decidimos después, por separado y por escrito, que es la sección 3.

Chequeo con hallazgo	Resultado	Sev.
columna constante o vacía	1 de 110: cob__sexo vale 1,0 en las 1.174 filas	ALTA
valor centinela en una clave	1 de 4: departamento = 'Enmascarado' en 63 filas de 23 jurisdicciones, 10.444 estudiantes (1,9%)	ALTA
bloque con cobertura menor al 50%	2 de 16: clima.escolar (91 filas) y educación del padre (1 fila)	MEDIA

Los ocho que dieron limpio, con su denominador: clave territorial duplicada 0 de 1.174, fila completa duplicada 0 de 1.174, proporción fuera de [0,1] 0 de 109, bloque de proporciones que no suma 1 0 de 18, columna con más del 30% de faltantes 0 de 131, columna casi constante 0 de 110, categoría con formato inconsistente 0 de 4 y fila sin ninguna variable analítica 0 de 1.174.

El faltante no es al azar, y por eso importa

Catorce de los dieciséis bloques tienen cobertura mediana por encima de 0,95; los dos que quedan abajo son educación del padre (0,904) y clima escolar (0,873). El que falla de verdad es clima escolar: 96 filas sin ningún dato y 91 con el dato calculado sobre menos de la mitad de los estudiantes de la fila. Los dos conjuntos son disjuntos, así que son **187 filas (15,9%) y 9.808 estudiantes (1,8%)**. La cobertura mediana cae de 0,921 en el quintil de grupos más grandes a 0,722 en el más chico, y por ámbito va de 0,921 urbano a 0,744 rural: **155 de las 187 filas afectadas son rurales**. El clima escolar está peor medido justo en las escuelas rurales chicas, que son las de mayor riesgo de abandono.

El caso 'Enmascarado' es el más traicionero porque nada avisaba: duplicados da 0 porque cada combinación de jurisdicción, 'Enmascarado', sector y ámbito es única, y el chequeo de formato tampoco lo veía porque la palabra está bien escrita. El Ministerio lo enmascara cuando el grupo es tan chico que identificaría a la escuela: esas 63 filas no son un departamento, son el agregado de los departamentos chicos de cada provincia.




Figura 2. Cobertura mediana por bloque de preguntas (izquierda) y cobertura de clima escolar según el tamaño del grupo (derecha). La curva de la derecha es el argumento: si el faltante fuera al azar, sería plana.

3. ¿Qué decisiones de curación tomamos?

«No queremos una base perfectamente limpia. Queremos una base cuyas decisiones de limpieza podamos explicar.»

El criterio común: ninguna de las cuatro decisiones borra filas ni modifica valores. Las cuatro hacen lo mismo, vuelven visible un problema en vez de taparlo, para que cualquier análisis posterior lo pueda excluir con una condición explícita y medir si excluirlo cambia el resultado. La razón es que los tres problemas que encontramos (clima escolar mal cubierto, departamentos enmascarados, valores extremos) golpean sobre todo a los grupos chicos y rurales, que son exactamente la población con mayor riesgo de abandono: limpiar por el camino fácil nos habría sesgado el dataset contra su propio objeto de estudio. Resultado: 1.174 x 131 pasa a **1.174 x 133**, mismas filas, dos columnas nuevas, ninguna modificada (verificado por assert).

1. Clima escolar: marcamos la calidad del dato, no tocamos el dato

Conservamos las tres columnas de clima escolar sin modificar y agregamos **clima_escolar_calidad** con tres estados: 'ok', 'cobertura_baja' y 'sin_dato'. Nos permite repetir cualquier análisis excluyendo las filas flojas y comprobar si el resultado cambia. *Descartamos imputar*, porque inventaríamos valores justo en el segmento donde el sesgo vive; *poner en NaN las 91 filas de baja cobertura*, porque perderíamos dato real sin dejar rastro visible de la pérdida; y *sacar el bloque*, porque tira una variable central del marco teórico por un problema que toca al 1,8% de los estudiantes.

2. Departamentos enmascarados: los identificamos, no los borramos

Conservamos las 63 filas y agregamos la columna booleana **es_agregado_provincial**. Un análisis por departamento filtra `es_agregado_provincial == False`; uno por provincia usa todas, que es donde estas filas sí suman bien. *Descartamos borrarlas*, porque se irían 10.444 estudiantes de los departamentos más chicos del país, que es el perfil de mayor riesgo, y los totales por provincia dejarían de cerrar contra Aprender; y *solo documentarlo*, porque deja la trampa disponible para el que no lea el documento.

3. Valores extremos: no los tocamos, y corregimos el chequeo

Al traducir la proporción a personas vemos que no son errores. En edad de 21 años, el 70% de las filas vale exactamente 0, lo que aplasta el rango intercuartílico a 0,0020 y deja el umbral de extremo en 0,0078: un solo estudiante de 21 años en un grupo de 118 da 0,0085 y ya lo supera. La mediana de estudiantes detrás de las 138 filas marcadas es **2,3 personas**, y 84 de 138 tienen menos de 3; el chequeo estaba marcando 'acá hay un estudiante de 21 años'. Así que no recortamos ni winsorizamos nada: corregimos el instrumento, y el perfil ahora reporta cuántas personas hay detrás de cada extremo, porque sin ese número el chequeo mentía por omisión. Descartamos winsorizar a los percentiles 1 y 99, porque borraría justamente los casos de sobreedad extrema, que son los que venimos a estudiar.

4. cob__sexo la conservamos pese a que tiene varianza cero

Una columna constante no aporta a un modelo, pero esta no es una variable predictiva: es metadato de cobertura y nunca iba a entrar a un modelo. La conservamos porque mantiene simétrica la familia (un bloque, una cobertura) y porque su valor constante es en sí mismo una verificación: si alguna vez deja de ser 1,0, algo cambió en la fuente o en el pipeline.

Cuánto mueven las decisiones

Ningún escenario mueve los indicadores más de un 1,3%. Eso no significa que las decisiones sobran: significa que los problemas estaban acotados y que ahora los tenemos acotados **y medidos**. La diferencia entre las dos situaciones es que antes no lo podíamos afirmar.

Escenario	Filas	Estudiantes	Mat. bajo básico	Sobreedad alta	Clima escolar bajo
todo el dataset	1.174	540.040	0,5434	0,0166	0,2039
sin agregados provinciales	1.111	529.596	0,5432	0,0168	0,2030
solo clima escolar 'ok'	987	530.232	0,5418	0,0164	0,2036
sin discrepancia entre bases	1.169	539.254	0,5434	0,0166	0,2038

4. ¿Qué variables o relaciones parecen especialmente interesantes?

El contexto socioeconómico provincial, con su robustez probada. La relación más fuerte del trabajo es entre el ingreso per cápita familiar mediano de la provincia y la proporción de estudiantes por debajo del nivel básico en matemática: **r = -0,82 sobre 24 jurisdicciones**. La siguen la proporción de adultos con nivel superior (-0,72), los adultos sin secundaria completa (+0,52) y el agua fuera de la vivienda (+0,52). La calculamos a nivel provincia y no sobre las 1.174 filas porque los valores de la EPH se repiten idénticos en todos los departamentos de una misma provincia: las filas no son observaciones independientes y calcular sobre ellas inflaría el n sin agregar información.

Pearson falla de dos maneras conocidas y cada prueba ataca una. Que la sostenga un solo caso raro: CABA es la jurisdicción más rica y la de mejor desempeño, está sola en ese rincón, la sacamos y la relación se mantiene. Que la relación sea fuerte pero curva: Spearman ignora la forma y mira solo el orden, y da más fuerte que Pearson, lo que sugiere que el salto entre las provincias más pobres pesa más que entre las más ricas. Sobrevive las tres pruebas: Pearson -0,82 (n = 24), Pearson sin CABA -0,73 (n = 23), Spearman -0,85 (n = 24) y Spearman sin CABA -0,83 (n = 23). Y el n es parte del dato, así que lo citamos siempre como **r = -0,82 sobre 24 jurisdicciones** y nunca como **r = -0,82 a secas**.

A nivel fila, donde las dos variables vienen de Aprender y varían entre departamentos, lo más fuerte contra el desempeño bajo en matemática es la ausencia de libros en papel en el hogar (Pearson +0,62, Spearman +0,64 sobre 1.174 filas) y la madre con terciario, universitario o posgrado completo (-0,62 y -0,59). Repitencia da +0,35 y sobreedad alta +0,21.




Figura 3. Ingreso per cápita familiar mediano provincial (EPH 3T-2025) contra desempeño bajo en matemática, una jurisdicción por punto y la matrícula como tamaño.

Las inasistencias, que quedan como pregunta y no como conclusión

Cuanto más chicos de un grupo reportan faltas, **menos** chicos de ese grupo están por debajo del básico: la proporción con 5 o más faltas correlaciona $-0,49$ con el desempeño bajo en matemática, la de 15 o más faltas $-0,37$, y la de los que dicen no faltar nunca da $+0,31$. La primera medición usamos solo la categoría más extrema (30 faltas o más) y nos dio $r = +0,000$: habríamos concluido que las inasistencias no se relacionan con nada. El error fue nuestro, miramos la cola en vez del acumulado, porque casi nadie cae en la categoría extrema (valor medio ponderado 0,10) y una columna que casi no varía no puede correlacionar con nada. Tampoco es la paradoja de Simpson: calculamos el mismo r dentro de cada celda de sector y ámbito y la relación negativa se mantiene en las cuatro (estatal rural $-0,34$, estatal urbano $-0,36$, privado rural $-0,59$, privado urbano $-0,49$).

Lo MEDIDO, verificado en la fuente. El Manual del Aplicador de Aprender 2024 dice que al finalizar ambas pruebas los estudiantes contestan un cuestionario complementario en un cuadernillo propio. O sea que el dato es **lo que el estudiante dice que faltó**, no un registro administrativo de asistencia.

Lo INFERIDO, explícitamente NO verificado. La hipótesis es que Aprender evalúa a quien está presente el día de la prueba, así que en una escuela con ausentismo real alto los más ausentes no entran a la muestra; entre los que sí rindieron, reportar faltas sería marcador de un alumno presente y conectado con la escuela, no de riesgo. Se suma que el dato es autorreporte: dos capas de ruido en la misma variable. Verificarlo requiere asistencia administrativa, que este dataset no tiene. Hasta entonces es una hipótesis, no un resultado.




Figura 4. Correlación de cada medida de inasistencia con el desempeño bajo en matemática (izquierda) y la misma relación abierta por sector y ámbito (derecha).

5. ¿Qué nuevas preguntas surgieron?

1. **¿De dónde sale el target?** Es la pregunta que manda. El dataset no tiene una variable de abandono, y el proxy construido en el TP1 desde la EPH correlaciona $+0,16$ con el desempeño, o sea que no mide lo que dice medir. Todo lo de arriba describe desempeño y sobreedad, antecedentes plausibles del abandono, no el abandono. Fuimos a buscar el target real y lo encontramos: está en la sección 7.
2. **¿Qué mide realmente la variable de inasistencias?** Contestarlo requiere cruzar el autorreporte con asistencia administrativa. Mientras tanto, no metemos la variable en un modelo sin una advertencia al lado.
3. **¿Por qué el sector pesa más que el ámbito?** Si la gestión explica más que la geografía, la pregunta siguiente es qué de la gestión: composición social de la matrícula, recursos, o algo que estas bases no observan.
4. **¿Cambia el resultado si excluimos las filas marcadas?** Ahora lo podemos probar con una condición de una línea, y si un modelo del TP3 nos da distinto al excluirlas, vamos a tener una columna que lo explique en vez de un misterio.

6. Limitaciones

No tenemos una variable de abandono. Describimos desempeño y sobreedad, no abandono. **Son correlaciones ecológicas:** valen entre agregados territoriales y no autorizan a concluir nada sobre un estudiante concreto.

La unidad de análisis es el grupo, no el estudiante. Toda pregunta que necesite abrir por atributo individual queda fuera de alcance con las bases publicadas. En particular la pregunta por sexo: las columnas de sexo dicen qué porcentaje del grupo son varones o mujeres, no cómo le fue a cada sexo. Lo único calculable es si los grupos con más mujeres rinden distinto, y da prácticamente cero ($-0,05$ y $+0,03$ sobre 1.174 filas): ese número responde una pregunta diferente de la que se hizo, así que reportamos el límite y no el número.

Todo lo que cruza con la EPH descansa en 24 puntos. Mover dos o tres cambia bastante el resultado. **Y el clima escolar está peor medido donde más importa:** 155 de las 187 filas afectadas son rurales, así que un modelo que use esa variable va a tener menos información precisamente donde más la necesita.

Los grupos chicos dan valores extremos por construcción. El quintil más chico (mediana 29 estudiantes) tiene 1,4 veces la dispersión del más grande (mediana 1.225) y llega a 0,000 y 1,000: todo número de una celda chica se cita con su

denominador.

Los períodos no coinciden, y lo vamos a corregir. Aprender se tomó en octubre de 2024 y la EPH que usamos es del tercer trimestre de 2025, porque es el archivo disponible en el repositorio del proyecto. En un país con nuestra inflación, un año de diferencia en una variable de ingresos no es menor. Unificar el marco temporal es la primera tarea de la sección 7.

El perfilado no sabe si un valor es correcto, solo si es posible. Eso lo cubren los 55 invariantes que corren contra los datos crudos. Y la reproducibilidad esta medida: dos corridas del pipeline dan 18 de 18 salidas idénticas byte a byte.

7. Qué sigue

Tres tareas, en este orden, antes del TP3. No son intenciones: las tres están medidas o tienen la fuente identificada.

1. Unificar el marco temporal. Rehacer la integración con la EPH del 3er trimestre de 2024, para que el contexto socioeconómico sea del mismo año que Aprender. Cambia el bloque de la EPH entero, así que tenemos que volver a correr las correlaciones de la sección 4 y ver cuánto se mueve el -0,82.

2. Traer el target real, que existe. El repositorio de referencia que nos recomendó la mentora publica las trayectorias oficiales por grado, y entre sus columnas está **salidos sin pase**, la definición administrativa del abandono intra-anual. Medimos el cruce contra nuestro dataset: pegan **1.174 de 1.174 claves en 2024** normalizando solo dos nombres de jurisdicción, y 1.070 de 1.174 tienen la serie completa de 14 años. Con tres advertencias que nos hacemos antes de festejar: que las claves peguen no prueba que midan la misma población (Aprender evalúa 5º y 6º año, las trayectorias cubren todos los grados); el target está muy desbalanceado, 46.720 salidos sin pase sobre 3.449.801 de matrícula, el **1,35%**; y en 249 de 1.209 filas el valor es cero sin que podamos distinguir un cero real de un dato faltante.

3. Preparar las variables para modelar. Encoding de las cuatro categóricas (sector y ámbito son binarias; jurisdicción son 24 categorías y pide target encoding antes que un one-hot que metería 24 columnas sobre 1.174 filas; departamento es un identificador y no entra), y un índice de contexto del hogar que junte libros y educación de la madre, que hoy miden lo mismo por dos caminos y compiten entre sí.