Dónde se concentra el abandono en la secundaria

Entregable 3 · Grupo M01 «El Factor D10S» · Lo que aprendimos al predecir el abandono escolar

Mentora: Noelia Ferrero · Diplomatura en Ciencia de Datos, FAMAF (UNC)

Fuentes: Aprender 2024 y Relevamiento Anual 2024 de escuelas

Código, datos y documentación: https://github.com/IVillanueva770/factor-d10s-m01

1. El problema

Queremos saber **en qué grupos de escuelas secundarias se concentra el abandono**, para que quien tenga que decidir dónde intervenir sepa por dónde empezar. Trabajamos con 1.174 grupos de escuelas (una provincia, un departamento, estatal o privado, urbano o rural) que juntan a 540.040 estudiantes. En los dos últimos años de la secundaria se registraron 11.732 estudiantes que dejaron la escuela sin pasar a otra, sobre 1.189.142 inscriptos: **0,99%**. Es un fenómeno chico en el total y muy desparejo entre lugares. Todo lo que sigue habla de grupos de escuelas, nunca de un estudiante en particular.

2. Lo que encontramos, en cinco líneas

1. Se puede ordenar qué grupos tienen más riesgo de abandono con lo que los estudiantes cuentan de sí mismos y de sus hogares en Aprender. Medimos qué tan bien ordena el riesgo en una escala donde 0,5 es un sorteo y 1 es perfecto: llegamos a **0,752**.

2. Pero casi todo eso ya lo dice la provincia. Con solo saber en qué provincia está el grupo se llega a 0,746. El modelo le gana por muy poco.

3. Sin conocer la provincia, el perfil de los estudiantes sigue diciendo algo. Probado en provincias que nunca vio, el modelo llega a 0,683, contra 0,651 de la regla «estatal o privado, urbano o rural».

4. Las provincias registran el abandono de forma muy distinta. La tasa va de 0,3% en San Luis a 3,9% en Misiones, unas 15 veces más. No podemos separar cuánto de eso es abandono real y cuánto es la forma de completar el registro.

5. Lo que más acompaña al abandono es lo conocido: hogares de menor nivel socioeconómico, madres que no terminaron la primaria, haber repetido y la gestión estatal. Es una asociación entre grupos, no una causa.

3. Qué significa para quien decide

Que lo que los estudiantes cuentan de sus hogares alcanza para señalar dónde mirar, aunque no explique por qué. Que ese señalamiento sirve dentro de una provincia y no entre provincias, porque los registros de abandono de cada una todavía no son comparables. Y que una parte del problema está en el dato: antes de afinar el modelo, conviene saber cómo se registra el abandono en cada lugar.

4. Qué haríamos con esto

- **Usarlo para ordenar dónde mirar primero dentro de cada provincia**, no para comparar provincias entre sí: entre provincias, el registro pesa tanto como el abandono.
- **Antes de cualquier uso, revisar con cada provincia cómo registra las salidas sin pase**, empezando por las que más se apartan de lo esperable (Buenos Aires y Santa Fe). Es la pregunta que este trabajo no puede cerrar y la que más cambia el resultado.
- **Dar una segunda mirada a los grupos que el modelo no marca.** Entre ellos quedan 156 con abandono alto. El perfil que más concentra es el de las escuelas estatales urbanas, que es además donde está la mayor parte de los estudiantes.
- **Sumar el Relevamiento 2025 cuando se publique**, para que el abandono y lo que cuentan los estudiantes hablen del mismo ciclo lectivo.

5. El modelo contra las reglas simples

Un modelo solo vale si le gana a una regla que cualquiera podría aplicar sin él. Comparamos dos modelos contra tres reglas: a todos el mismo riesgo (un sorteo), el riesgo de su combinación de sector y ámbito, y el riesgo de su provincia. Con todas las provincias a la vista, el mejor modelo llega a 0,752 y la regla de la provincia a 0,746: prácticamente empatan. El segundo modelo, más complejo, no mejora (0,734), señal de que el patrón es simple. La diferencia aparece cuando probamos en provincias que el modelo nunca vio: ahí la regla de la provincia no tiene nada que decir y el modelo conserva 0,683.

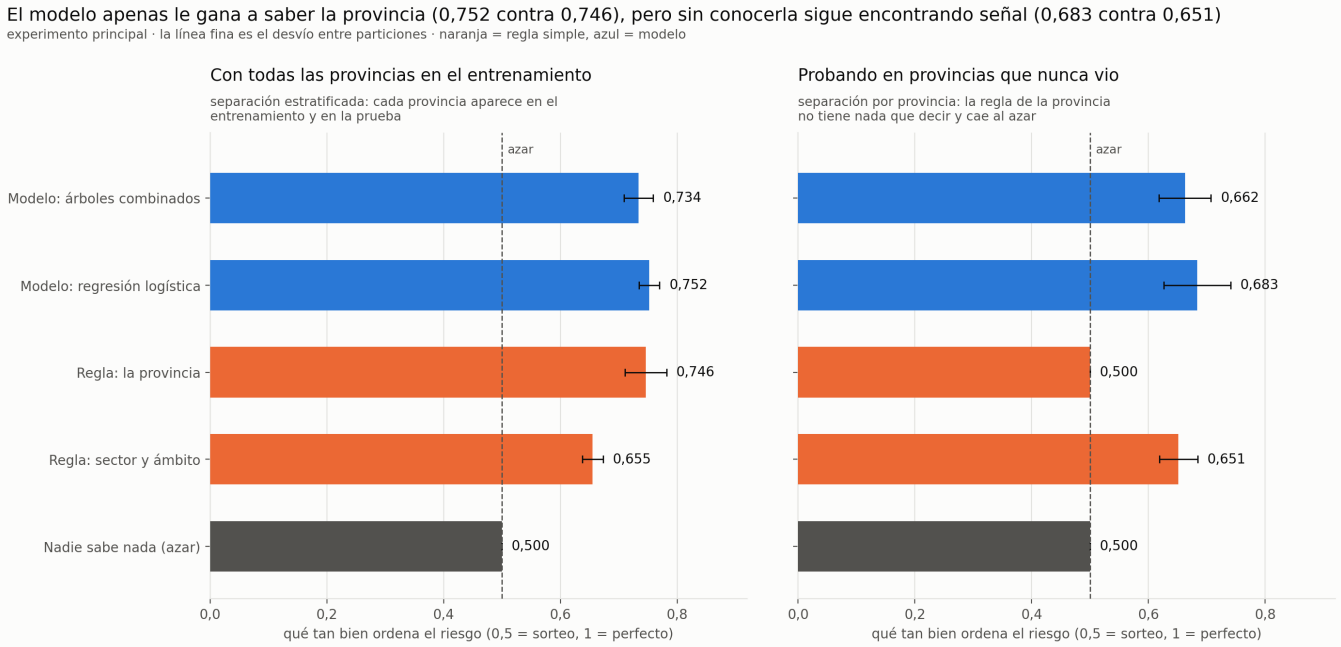


Figura 1. Qué tan bien ordena el riesgo cada modelo y cada regla (0,5 es un sorteo, 1 es perfecto). Azul, los modelos; naranja, las reglas simples. Izquierda: todas las provincias a la vista. Derecha: probando en provincias que el modelo no vio.

6. Las provincias registran distinto

Los errores del modelo no se reparten parejo entre provincias, y es lo más importante que aprendimos. En Buenos Aires hay 22 grupos con abandono alto y el modelo detecta 1, pero marca otros 17 que el registro da como bajos: por el perfil de sus estudiantes, esos grupos «deberían» tener más abandono del que figura. En Santa Fe pasa al revés: 34 grupos con abandono alto y el modelo detecta 7. O cada provincia registra distinto, o hay algo propio de cada una que Aprender no ve. Con estos datos no lo podemos distinguir, y por eso proponemos revisarlo con ellas antes de usar el modelo.

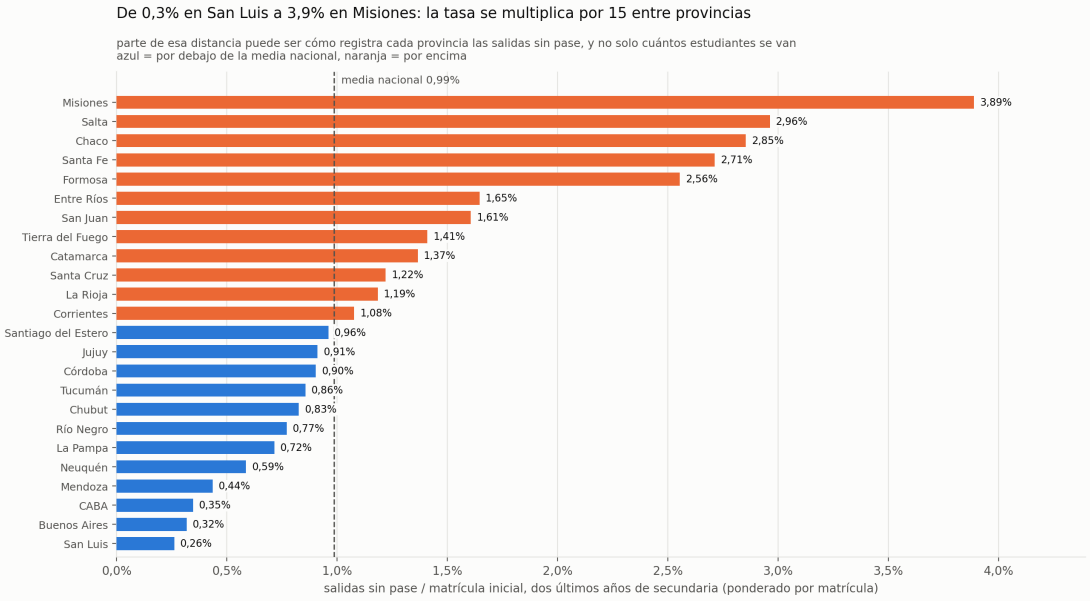


Figura 2. Tasa de abandono registrada en los dos últimos años de la secundaria, por provincia. Naranja, por encima de la media nacional; azul, por debajo.

7. Los grupos que el modelo no marca

La mentora propuso una segunda mirada sobre los grupos que el modelo no marca como abandono alto. Los agrupamos por seis rasgos parecidos (sin usar el abandono para armarlos) y aparecen 4 perfiles. El privado urbano casi no tiene abandono. Los otros tres (estatal urbano, rural estatal y rural más vulnerable) tienen tasas parecidas entre sí, y entre todos los no marcados quedan 156 grupos con abandono alto que el modelo no vio. El perfil que más concentra es el estatal urbano.

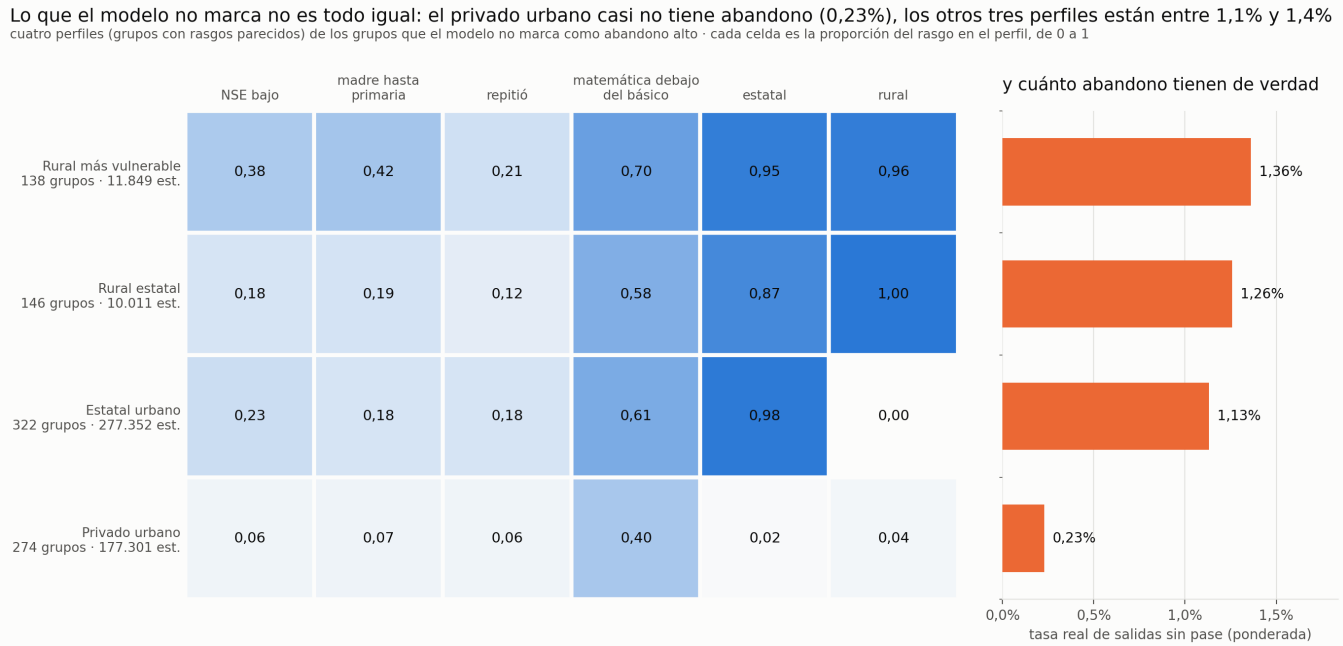


Figura 3. Los cuatro perfiles de grupos que el modelo no marca. Cada celda es la proporción del rasgo en el perfil (de 0 a 1); a la derecha, cuánto abandono registran de verdad.

Qué acompaña al abandono. Más abandono donde hay más hogares de nivel socioeconómico bajo, más madres que no terminaron la primaria, más repitencia, más estudiantes que empezaron el jardín recién en sala de 5, y en la gestión estatal. Ningún tema por separado es imprescindible: al sacar uno, los otros lo cubren, porque cuentan la misma historia de desigualdad. Que algo acompañe al abandono no lo vuelve causa: sirve para saber dónde mirar, y qué cambiar es otra pregunta.

8. Cómo lo analizamos

Dos fuentes que miran cosas distintas. Aprender lo responde el estudiante el día de la prueba: cuenta cómo le va y cómo vive, pero no puede ver el abandono, porque el que ya se fue no rinde. El Relevamiento Anual lo completa cada escuela: cuenta quién se fue, pero no sabe nada de los hogares. Las unimos por grupo de escuelas, todo en 2024. **Qué predecimos:** la tasa de abandono es la cantidad de salidas sin pase de los dos últimos años dividida por los inscriptos de esos años (la misma población que evalúa Aprender), y un grupo tiene abandono alto si su tasa está en el cuarto más alto del país (1,74% o más; son 294 grupos). **Contra qué nos medimos:** las tres reglas simples de la sección 5. **Sin mirar la respuesta:** no usamos nada que se conozca después del resultado (los no promovidos, los pases ni los egresados del mismo año), y cada grupo lo evaluó un modelo que no lo había visto. **Lo que no aportó:** sumar dos indicadores de la Encuesta Permanente de Hogares por provincia, como pidió la mentora, deja el resultado en 0,751: lo que dice de la provincia ya lo dice Aprender.

9. Limitaciones

- **Grupos, no personas.** Nada de esto permite decir algo de un estudiante concreto.
- **El abandono registrado no es el abandono real.** Un cero no se distingue de «no se registró», y las provincias registran muy distinto.
- **Lo que medimos es inestable.** De los grupos con abandono alto en 2024, solo el 53% ya lo tenía el año anterior: en grupos chicos, una sola salida mueve la tasa entera.
- **Probable desfase de un año.** El archivo 2024 del Relevamiento parece traer el ciclo 2023; lo inferimos de los datos y lo dejamos declarado.
- **Aprender solo ve a quien fue a rendir**, y eso subestima justo a los grupos con más abandono.

10. Qué sigue

- Sumar el Relevamiento 2025 para que todo hable del mismo ciclo.
- Incorporar el abandono interanual oficial (quién no se reinscribe al año siguiente), que capta lo que las salidas sin pase no ven.
- Revisar con las provincias cómo registran las salidas sin pase, empezando por Buenos Aires y Santa Fe.
- Predecir el año siguiente con los datos del anterior, que es lo que haría un sistema de alerta temprana de verdad.

Código, datos y documentación: https://github.com/IVillanueva770/factor-d10s-m01

Notebook en Colab: PENDIENTE

Nota para lectores técnicos: la escala de 0,5 a 1 es el área bajo la curva ROC (ROC-AUC); los dos modelos son una regresión logística y un boosting de árboles; los perfiles salen de k-means sobre seis rasgos; la evaluación es una cross-validation de cinco particiones, estratificada y también agrupada por provincia, sin leakage de variables posteriores al resultado.