Dónde se concentra el abandono en la secundaria argentina

Cruzamos lo que 540.040 estudiantes contaron en las Pruebas Aprender con los chicos que sus escuelas registraron como abandono. Entregable 3 del grupo M01, “El Factor D10S”.

Integrantes: Pablo Micheli, Jorge Luis Mira e Ignacio Villanueva
Mentora: Noelia Ferrero · Mentoría de la Diplomatura en Ciencia de Datos, FAMAF (UNC), 2026

1. El problema y los datos

Queremos saber **en qué grupos de escuelas secundarias se concentra el abandono**, para que quien tenga que decidir dónde intervenir sepa por dónde empezar. Usamos dos fuentes públicas del Ministerio de Educación que miran cosas distintas. Las **Pruebas Aprender** son la evaluación nacional que rinden los estudiantes del último año: además de la prueba, responden un cuestionario sobre su hogar, su trayectoria y su escuela. El **Relevamiento Anual** es el formulario que cada escuela completa todos los años: cuenta cuántos chicos se inscribieron, cuántos pasaron de año y cuántos se fueron. Aprender no puede ver el abandono, porque el que ya dejó no va a rendir; el Relevamiento sí, pero no sabe nada de los hogares. La **Encuesta Permanente de Hogares** (EPH, la encuesta oficial del INDEC sobre empleo e ingresos de los hogares) tampoco sirve para medir el abandono acá: no se puede unir a estos grupos, porque solo llega a provincia, y su dato es de 2025.

La pregunta de partida era qué estudiante abandona, pero Aprender no se publica estudiante por estudiante sino por **grupo de escuelas**: un departamento de una provincia, separando escuelas estatales y privadas, urbanas y rurales. Son 1.174 grupos con 540.040 estudiantes, y todo lo que sigue habla de esos grupos, nunca de un chico en particular. Llamamos **perfil** de un grupo a lo que cuentan sus estudiantes en Aprender sobre su hogar, su trayectoria y su escuela. Como abandono usamos las **salidas sin pase**: estudiantes que dejaron la escuela sin inscribirse en otra. En los dos últimos años de la secundaria fueron 11.732 sobre 1.189.142 inscriptos, el **0,99%**: poco en el total y muy desparejo entre lugares. Decimos que un grupo tiene **abandono alto** si está en el cuarto de grupos con la tasa más alta del país (1,74% o más).

2. Lo que encontramos, en cinco líneas

Probamos dos modelos que miran solo el perfil (una regresión logística y otro de árboles combinados) y un tercero que además conoce la provincia. Cuando decimos **el modelo** hablamos de la regresión logística con el perfil solo. Para medirlos usamos una escala de qué tan bien ordenan los grupos de más a menos riesgo: **0,5 es lo que lograría un sorteo y 1 es ordenarlos perfecto**. 0,75 quiere decir que si tomamos un grupo con abandono alto y uno sin, el modelo pone primero al de abandono alto 3 de cada 4 veces (y 0,80, 4 de cada 5). Además, el modelo **marca** como de riesgo al cuarto de grupos que pone más arriba: de los 294 grupos con abandono alto encuentra 138 (47%), y de sus 294 marcas aciertan 138 (47%).

1. **Con el perfil de los estudiantes se puede ordenar qué grupos tienen más riesgo de abandono:** el modelo llega a **0,75**.
2. **La provincia y el perfil aportan información distinta.** Con solo saber en qué provincia está el grupo se llega a 0,75, lo mismo que con el perfil. Juntos llegan a **0,80**: lo que sabe uno no lo sabe el otro.
3. **Sin conocer la provincia, el perfil dice poco más que la regla simple.** Probado en provincias que nunca vio, el modelo llega a 0,68, contra 0,65 de mirar solo si la escuela es estatal o privada, urbana o rural. La diferencia (0,03) es menor que lo que varía el resultado de una prueba a otra (0,06).
4. **El abandono registrado cambia mucho de una provincia a otra:** de 0,26% en San Luis a 3,89% en Misiones, unas 15 veces más. Creemos que una parte es la forma de completar el registro y no abandono real, pero es una hipótesis nuestra: el área de estadística del Ministerio de Educación sostiene que el dato es comparable entre provincias.
5. **Lo que más acompaña al abandono coincide en buena parte con lo que ya documenta la investigación en Argentina:** hogares de nivel socioeconómico bajo, madres que no terminaron la primaria, haber repetido, tener más edad de la que corresponde al año, haber empezado el jardín recién en sala de 5 y la escuela estatal (sección 6). Es una asociación entre grupos, no una causa.

3. Qué significa para quien decide

Que lo que los estudiantes cuentan de sus hogares sirve para ordenar dónde mirar, también dentro de una misma provincia, aunque no explique por qué pasa. Sumarle la provincia ordena mejor, pero no sabemos cuánto de lo que aporta la provincia es abandono y cuánto es la forma de registrarlo: antes de usarla para comparar provincias entre sí, conviene saber cómo registra el abandono cada una.

4. Qué haríamos con esto

- **Mientras no se revise cómo registra cada provincia, usar el perfil para ordenar dentro de cada provincia**, y tomar la provincia como un dato a revisar. Es una señal modesta, pero es la única que no depende de cómo registra cada provincia: si el abandono alto se define dentro de cada provincia (el cuarto de sus grupos con la tasa más alta), el perfil ordena en 0,66, contra 0,62 de la regla estatal/privado y urbano/rural.
- **Antes de comparar provincias, revisar con ellas cómo registran las salidas sin pase**, empezando por las que más se apartan de lo que predice el modelo (Buenos Aires y Santa Fe).
- **Dar una segunda mirada a los grupos que el modelo no marca:** entre ellos quedan 156 de los 294 con abandono alto, 72 en escuelas estatales urbanas y 76 en estatales rurales (sección 8).

5. El modelo contra las reglas simples

Un modelo solo vale si le gana a una regla que cualquiera podría aplicar sin él. Por eso comparamos los modelos contra tres reglas: darle a todos el mismo riesgo (un sorteo), darle a cada grupo el riesgo promedio de los grupos de su mismo tipo (estatal o privado, urbano o rural), y darle el riesgo promedio de su provincia. Con todas las provincias a la vista, el modelo llega a 0,75 y la regla de la provincia a 0,75: empatan. El de árboles combinados, más complejo, no mejora (0,73), señal de que el patrón es simple. Pero empatar no es saber lo mismo: el modelo que conoce la provincia y el perfil a la vez llega a **0,80** (la barra de arriba de la figura 1). Si la provincia solo resumiera el perfil de sus estudiantes, sumarla no agregaría nada.

Sin la provincia, el perfil dice poco: si probamos el modelo en provincias que no usó para aprender, la regla de la provincia queda sin nada que decir y el modelo llega a 0,68, apenas por encima de la regla estatal/privado y urbano/rural (0,65). Elegir el cuarto de grupos con más abandono como “alto” fue decisión nuestra, así que lo movimos al tercio y al quinto: el perfil solo y la provincia sola siguen parejos (en los dos casos, 0,74 contra 0,75).

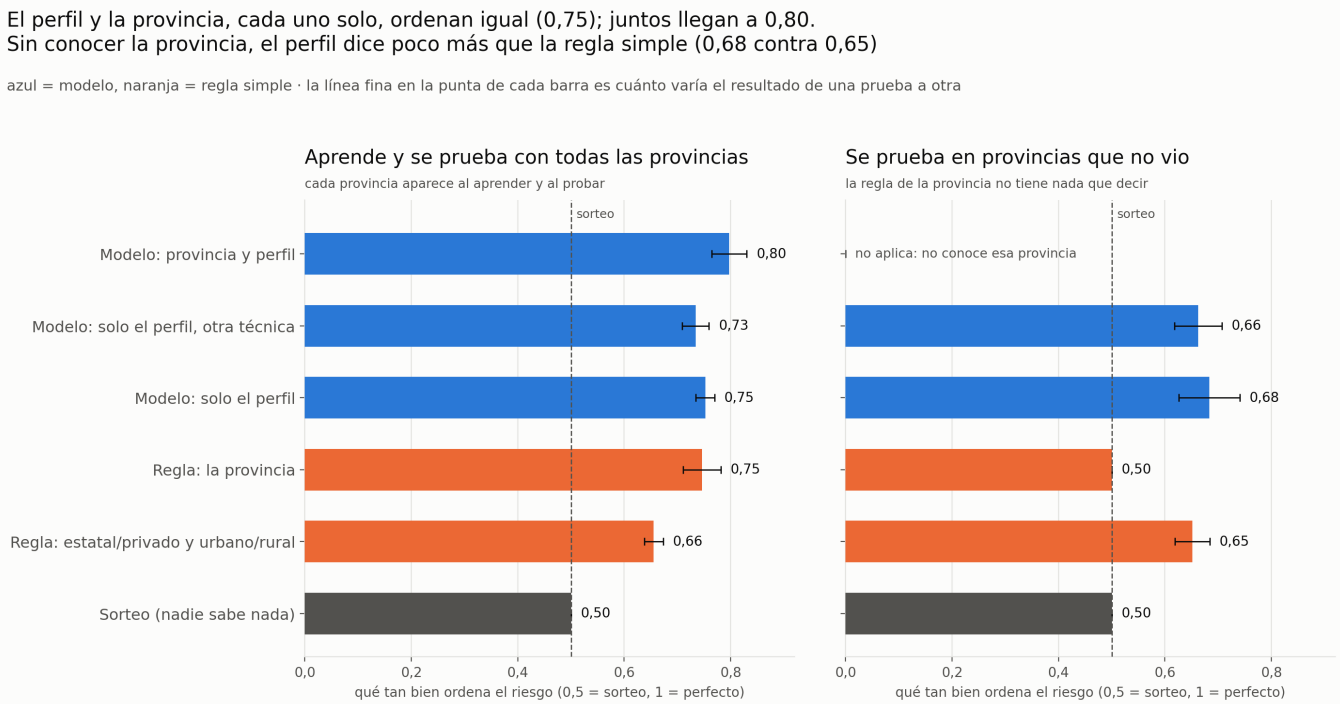


Figura 1. Qué tan bien ordena el riesgo cada modelo y cada regla (0,5 es un sorteo, 1 es perfecto). Azul, los modelos; naranja, las reglas simples. Izquierda: el modelo aprende y se prueba con todas las provincias. Derecha: se prueba en provincias que no vio. La línea fina en la punta de cada barra muestra cuánto varía el resultado de una prueba a otra.

6. Qué acompaña al abandono, y qué ya se sabía

En nuestros datos hay más abandono donde hay más hogares de nivel socioeconómico bajo, más madres que no terminaron la primaria, más estudiantes que repitieron o que tienen más edad de la que corresponde al año, más que empezaron el jardín recién en sala de 5, y en las escuelas estatales. No lo dimos por sentado: buscamos qué dice la investigación previa.

- **Nivel socioeconómico y escuela estatal: documentado.** Un estudio de Adrogué y Orlicki (2025), que siguió veinte años de la Encuesta Permanente de Hogares del INDEC, encuentra más riesgo de abandono en los hogares más pobres y en las escuelas de gestión estatal.
- **Educación de la madre: documentado.** La encuesta de UNICEF Argentina sobre adolescencias (2022) lo muestra como "clima educativo del hogar". Ojo: en Aprender 2024 el índice de nivel socioeconómico ya incluye la educación de la madre, así que en nuestros datos no son dos señales independientes.
- **Repitencia y sobreedad: documentado con dato oficial.** El área de estadística del Ministerio de Educación mostró en 2024 un abandono del 27% entre quienes tienen sobreedad contra 4,5% entre quienes no (con otra forma de medir el abandono, que sigue a cada estudiante a lo largo de los años, en 11 provincias).
- **Jardín desde sala de 3: documentado en parte.** El informe nacional de Aprender 2024 lo asocia a mejores aprendizajes, pero no encontramos una fuente argentina que lo mida contra el abandono.

Ningún tema por separado es imprescindible para el modelo: al sacar uno, los otros lo cubren, porque todos cuentan la misma desigualdad. Y que algo acompañe al abandono no lo vuelve causa: sirve para saber dónde mirar; qué cambiar es otra pregunta.

7. Abandono o forma de registrar

Los errores del modelo no se reparten parejo entre provincias. En Buenos Aires hay 22 grupos con abandono alto y el modelo detecta 1, pero marca otros 17 que el registro da como bajos: por el perfil de sus estudiantes, esos grupos "deberían" tener más abandono del que figura. En Santa Fe pasa al revés: 34 grupos con abandono alto y el modelo detecta 7. O cada provincia registra distinto, o hay algo propio de cada una que Aprender no ve; con estos datos no lo podemos distinguir.

Que el registro cambie entre provincias es una hipótesis nuestra. El área de estadística del Ministerio de Educación, que administra el Relevamiento, sostiene lo contrario: que su sistema "garantiza la homogeneidad y comparabilidad de los datos en todo el ámbito nacional". No encontramos ningún documento oficial que advierta diferencias. Nos apoyamos en la distancia entre provincias y en la caída de Buenos Aires, que con la secundaria entera pasa de 2,97% en 2011 a 0,30% en 2024. Por eso proponemos revisarlo con las provincias antes de compararlas.

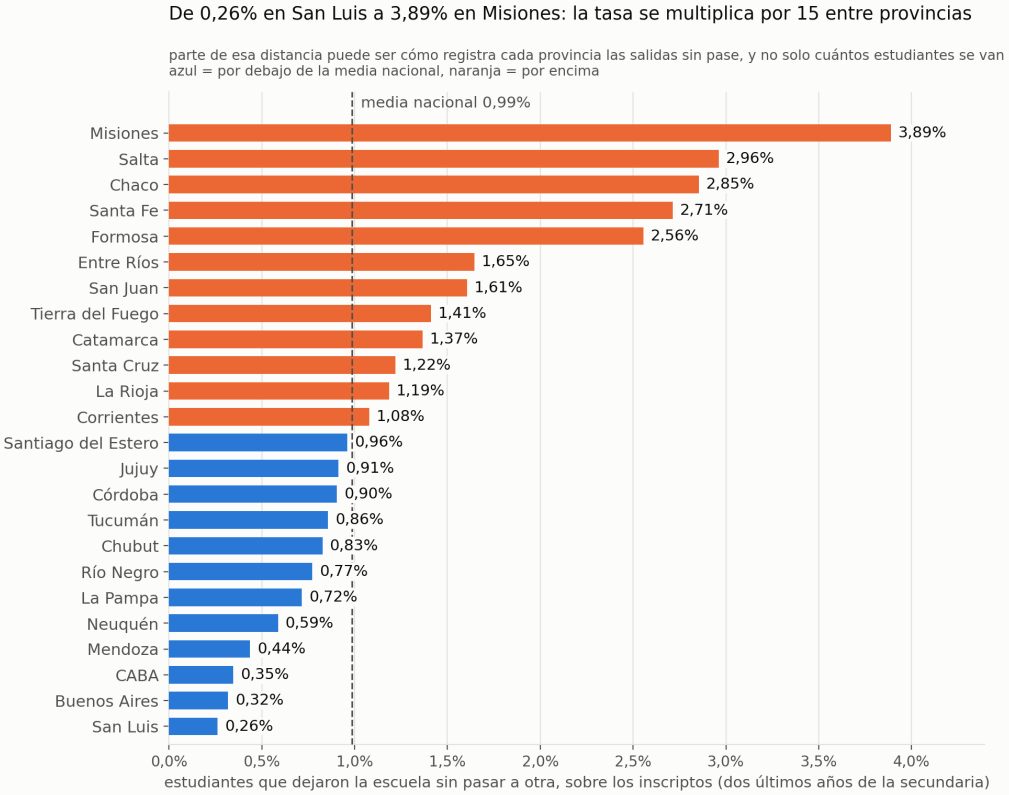


Figura 2. Abandono registrado en los dos últimos años de la secundaria, por provincia. Naranja, por encima de la media nacional; azul, por debajo.

8. Los grupos que el modelo no marca

La mentora propuso una segunda mirada: dentro de los grupos que el modelo no marca como abandono alto, ¿hay perfiles distintos? Los agrupamos por seis rasgos (nivel socioeconómico, educación de la madre, repitencia, desempeño en matemática, sector y ámbito), sin usar el abandono para armarlos, y aparecen 4 perfiles. El privado urbano casi no tiene abandono. Los otros tres (estatal urbano, rural estatal y rural más vulnerable) tienen tasas parecidas entre sí. Entre todos los no marcados quedan 156 de los 294 grupos con abandono alto: 72 (46%) en el estatal urbano y 76 entre los dos rurales.

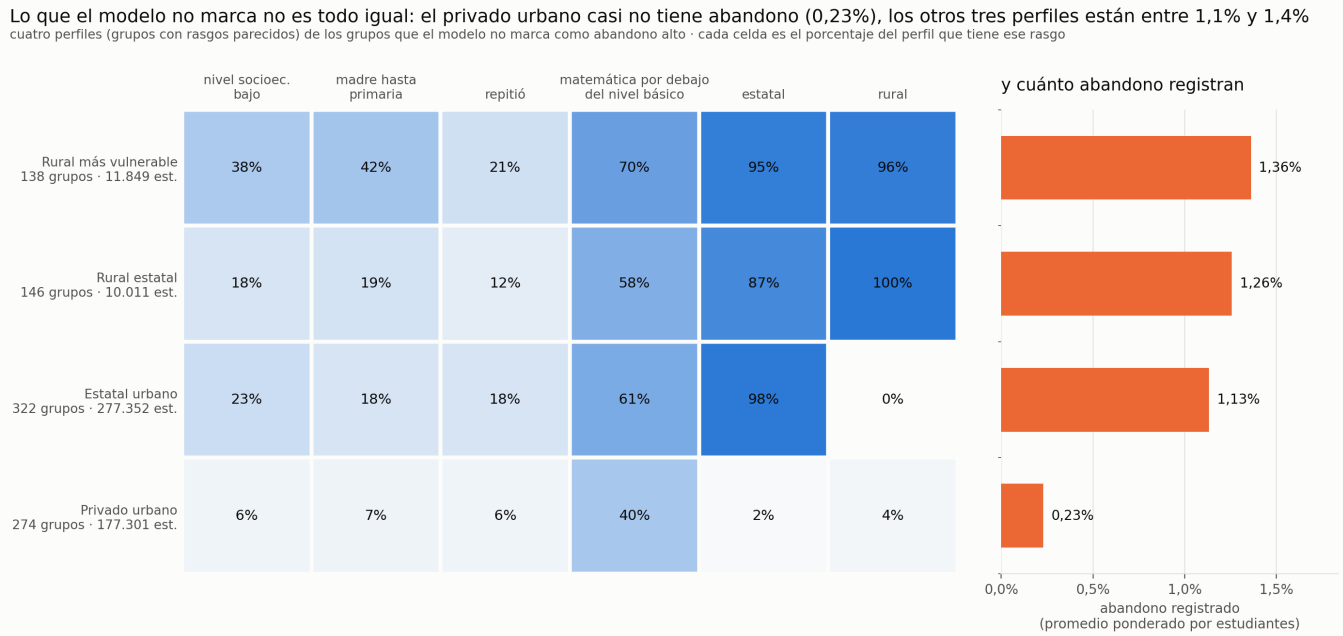


Figura 3. Los cuatro perfiles de grupos que el modelo no marca. Cada celda es el porcentaje del perfil que tiene ese rasgo; a la derecha, cuánto abandono registran.

Para quien decide: el estatal urbano junta más casos por su tamaño (reúne el 58% de los estudiantes de estos grupos); el rural más vulnerable tiene la tasa más alta.

9. Cómo lo analizamos

Qué predecimos. Si un grupo tiene abandono alto, con la regla de la sección 1. Para la definición de salida sin pase usamos la oficial del área de estadística del Ministerio de Educación: “el que se va de la escuela a la que asistía, sin inscripción (o pase) en otra escuela”. Tomamos los dos últimos años porque son los que evalúa Aprender.

Con qué modelos. Una regresión logística, que estima la probabilidad de abandono alto sumando el peso de cada variable y se puede leer, y un modelo de árboles combinados (boosting), que capta relaciones no lineales. La escala de 0,5 a 1 con la que los comparamos es el área bajo la curva ROC. Los perfiles de la sección 8 salen de un agrupamiento k-means.

Qué acompaña al abandono. La lista de las secciones 2 y 6 no sale de los pesos de la regresión: miramos la correlación de cada respuesta con la tasa de abandono, para ver hacia dónde empuja, y cuánto empeora el modelo al sacar cada tema, para ver cuánto aporta.

Sin mirar la respuesta. Cada grupo lo evaluó un modelo que no lo había visto: partimos los datos en cinco y cada parte se predijo con lo aprendido de las otras cuatro. No usamos nada que se conozca después del abandono (los que no pasaron de año, los pases ni los egresados del mismo año).

La encuesta de hogares. Como pidió la mentora, probamos sumar dos indicadores de la EPH por provincia: el ingreso per cápita mediano del hogar y la proporción de adultos sin secundaria completa. Con la regresión logística no cambia (0,75), pero con árboles combinados sube de 0,73 a 0,77: dos datos por provincia alcanzan para que el modelo reconozca la provincia, que es la información que el perfil no tiene.

10. Limitaciones

- **Grupos, no personas.** Nada de esto permite decir algo de un estudiante concreto.
- **El abandono registrado no es el abandono real.** Un cero no se distingue de “no se registró”, y hay muchos: 375 de los 1.174 grupos (32%) no tienen ninguna salida registrada. Que la diferencia entre provincias sea por cómo registra cada una es una hipótesis nuestra (sección 7).
- **Lo que el registro no cuenta y lo que cuenta de más.** Quien se va entre diciembre y marzo, después del último día de clase, no figura como salida sin pase, según el formulario 2025 del Relevamiento; y la categoría incluye a quienes siguen en otra escuela sin haber hecho el trámite del pase.
- **Un año de diferencia.** El Relevamiento de cada año informa las salidas del ciclo anterior: el de 2024 trae las de 2023, y Aprender es de octubre de 2024. Es decir, el perfil se midió después del abandono con el que lo comparamos: esto ordena, no anticipa. Anticipar es el próximo paso.
- **Lo que medimos es inestable.** De los grupos con abandono alto en el Relevamiento 2024, solo el 53% lo tenía en el anterior (por azar sería el 25%): en grupos chicos, una sola salida mueve la tasa.
- **El modelo detecta peor a los grupos más grandes.** En el quinto de grupos más grandes encuentra el 34% de los que tienen abandono alto, contra el 47% en el quinto más chico: ahí las tasas son más bajas y parejas, y lo poco que pasa queda diluido.
- **Aprender solo ve a quien fue a rendir**, y eso subestima justo a los grupos con más abandono.

11. Próximos pasos

- Sumar el Relevamiento 2025, que trae el abandono del ciclo 2024, el mismo año de Aprender.
- Incorporar el abandono interanual oficial (quiénes no se reinscriben al año siguiente), que capta lo que las salidas sin pase no ven.
- Revisar con las provincias cómo registran las salidas sin pase, empezando por Buenos Aires y Santa Fe.
- Predecir el año siguiente con los datos del anterior, que es lo que haría un sistema de alerta temprana.

El notebook que reproduce todo, el código y la lista completa de fuentes con sus citas textuales y enlaces están en el repositorio del proyecto: github.com/IVillanueva770/factor-d10s-m01. El notebook se puede abrir y correr en Colab sin instalar nada.

12. Fuentes

Adrogué, C. y Orlicki, E. (2025). Riesgo de abandono escolar en la secundaria. Factores comunes y diferentes para varones y mujeres. Estudios Económicos 42(85), 58-79. Universidad Nacional del Sur.

Dirección Nacional de Información y Evaluación de la Calidad Educativa (DiNIECE), Ministerio de Educación, Ciencia y Tecnología (s/f). Definiciones básicas para la producción de estadísticas educativas.

Dirección de Información y Estadística Educativa (DIEE) (s/f). Bases Usuarias Relevamiento Anual. Documento metodológico.

Relevamiento Anual 2025. Educación Común. Matrícula y cargos (cuadernillo nacional, 2025).

Subsecretaría de Información y Evaluación Educativa, Ministerio de Capital Humano (2025). Informe de resultados 2024. Educación Secundaria (Aprender 2024).

Subsecretaría de Información y Evaluación Educativa, Ministerio de Capital Humano (2024). Caminos interrumpidos: abandono escolar y sobreedad. Historias con datos.

UNICEF Argentina (2022). Encuesta Nacional de Niñas, Niños y Adolescentes. MICS 2019-2020. Informe temático: Adolescencias y educación.