Dónde se concentra el abandono en la secundaria

Entregable 3 · Grupo M01 «El Factor D10S» · Lo que aprendimos al predecir el abandono escolar

Mentora: Noelia Ferrero · Diplomatura en Ciencia de Datos, FAMAF (UNC)

Fuentes: Aprender 2024 y Relevamiento Anual 2024 de escuelas

Código, datos y documentación: https://github.com/IVillanueva770/factor-d10s-m01

1. El problema

Queremos saber **en qué grupos de escuelas secundarias se concentra el abandono**, para que quien tenga que decidir dónde intervenir sepa por dónde empezar. Trabajamos con 1.174 grupos de escuelas (una provincia, un departamento, estatal o privado, urbano o rural) que juntan a 540.040 estudiantes. En los dos últimos años de la secundaria se registraron 11.732 estudiantes que dejaron la escuela sin pasar a otra, sobre 1.189.142 inscriptos: **0,99%**. Es un fenómeno chico en el total y muy desparejo entre lugares. Todo lo que sigue habla de grupos de escuelas, nunca de un estudiante en particular.

2. Lo que encontramos, en cinco líneas

1. Se puede ordenar qué grupos tienen más riesgo de abandono con lo que los estudiantes cuentan de sí mismos y de sus hogares en Aprender. Medimos qué tan bien ordena el riesgo en una escala donde 0,5 es un sorteo y 1 es perfecto: llegamos a **0,752**.

2. La provincia y el perfil de los estudiantes aportan información distinta. Cada uno solo ordena el riesgo parecido: con solo saber en qué provincia está el grupo se llega a 0,746, casi lo mismo que con el perfil. Juntos llegan a **0,797**: lo que sabe uno no lo sabe el otro.

3. Sin conocer la provincia, el perfil de los estudiantes sigue diciendo algo. Probado en provincias que nunca vio, el modelo llega a 0,683, contra 0,651 de la regla «estatal o privado, urbano o rural».

4. La tasa registrada cambia mucho de una provincia a otra. Va de 0,3% en San Luis a 3,9% en Misiones, unas 15 veces más. Pensamos que una parte es la forma de completar el registro y no abandono real, pero es una hipótesis nuestra: el documento oficial del Relevamiento sostiene que los datos son comparables entre provincias, y no encontramos ninguno que advierta lo contrario.

5. Lo que más acompaña al abandono coincide con lo que ya documenta la investigación argentina: hogares de menor nivel socioeconómico, madres con menos educación, haber repetido y tener más edad de la que corresponde (sección 6, con las fuentes). Es una asociación entre grupos, no una causa.

3. Qué significa para quien decide

Que lo que los estudiantes cuentan de sus hogares y la provincia donde estudian, juntos, señalan dónde mirar mejor que cada uno por separado, aunque no expliquen por qué. Y que una parte del problema está en el dato: antes de comparar provincias entre sí, conviene saber cómo registra el abandono cada una.

4. Qué haríamos con esto

- **Usar la provincia y el perfil de los estudiantes juntos para ordenar dónde mirar primero**: juntos ordenan mejor que cada uno por separado.
- **Antes de comparar provincias entre sí, revisar con ellas cómo registran las salidas sin pase**, empezando por las que más se apartan de lo que predice el modelo (Buenos Aires y Santa Fe). Es la pregunta que este trabajo no puede cerrar y la que más cambia el resultado.
- **Dar una segunda mirada a los grupos que el modelo no marca.** Entre ellos quedan 156 con abandono alto. El perfil que más concentra es el de las escuelas estatales urbanas, que es además donde está la mayor parte de los estudiantes.
- **Sumar el Relevamiento 2025 cuando se publique**: trae el abandono del ciclo 2024, el mismo en que los estudiantes respondieron Aprender.

5. El modelo contra las reglas simples

Un modelo solo vale si le gana a una regla que cualquiera podría aplicar sin él. Comparamos dos modelos contra tres reglas: a todos el mismo riesgo (un sorteo), el riesgo de su combinación de sector y ámbito, y el riesgo de su provincia. Con todas las provincias a la vista, el mejor modelo llega a 0,752 y la regla de la provincia a 0,746: prácticamente empatan. El segundo modelo, más complejo, no mejora (0,734), señal de que el patrón es simple. Pero empatar no es saber lo mismo: un único modelo que conoce la provincia y el perfil llega a **0,797** (la barra de arriba de la figura 1). Si la provincia solo resumiera el perfil de sus estudiantes, sumarla no agregaría nada. Y el perfil sirve sin la provincia: probando en provincias que el modelo nunca vio, la regla de la provincia no tiene nada que decir y el modelo conserva 0,683. El corte del cuarto superior es una decisión nuestra: lo movimos al tercio y al quinto superior y la conclusión aguanta, el perfil solo y la provincia sola quedan parejos (0,742 contra 0,749, y 0,741 contra 0,751).

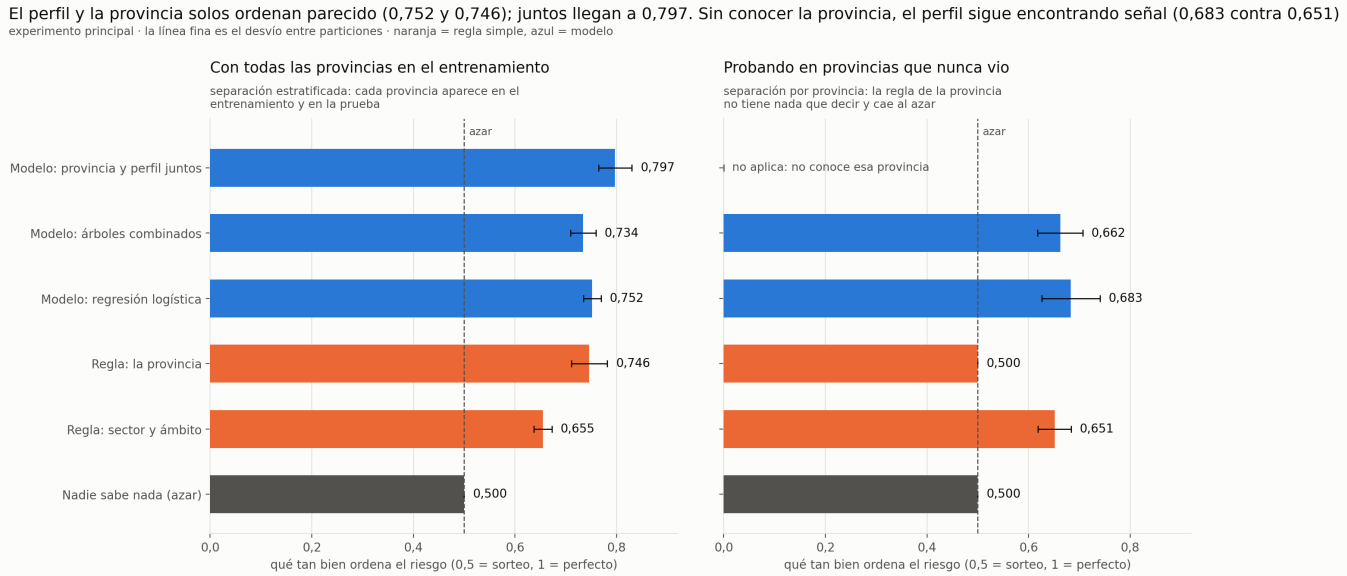


Figura 1. Qué tan bien ordena el riesgo cada modelo y cada regla (0,5 es un sorteo, 1 es perfecto). Azul, los modelos; naranja, las reglas simples. Izquierda: todas las provincias a la vista. Derecha: probando en provincias que el modelo no vio.

6. Qué acompaña al abandono, y qué ya se sabía

Más abandono donde hay más hogares de nivel socioeconómico bajo, más madres que no terminaron la primaria, más repitencia, más estudiantes que empezaron el jardín recién en sala de 5, y en la gestión estatal. No lo damos por sentado: lo buscamos. Está documentado para el nivel socioeconómico (Adrogué y Orlicki, 2025; UNICEF Argentina, 2022), para la educación de la madre, como «clima educativo del hogar» (UNICEF Argentina, 2022; Boniolo y Najmias, 2018; Argentinos por la Educación, 2023), y para la repitencia y la sobreedad, con dato oficial (Subsecretaría de Información y Evaluación Educativa, 2024; Aprender 2024). Lo del jardín está documentado para los aprendizajes y para terminar la secundaria (Aprender 2024; Berlinski y otros, 2025), pero no encontramos una fuente argentina que lo mida contra el abandono. La brecha de la gestión estatal está documentada (Adrogué y Orlicki, 2025; Argentinos por la Educación, 2023); que se explique por quiénes asisten, solo para los aprendizajes (Albornoz y otros, 2016). Una advertencia: en Aprender 2024 el nivel socioeconómico ya incluye la educación de la madre (informe nacional, p. 30), así que no son dos señales independientes. Ningún tema por separado es imprescindible: al sacar uno, los otros lo cubren. Que algo acompañe al abandono no lo vuelve causa: sirve para saber dónde mirar, y qué cambiar es otra pregunta.

7. Abandono o forma de registrar

Los errores del modelo no se reparten parejo entre provincias. En Buenos Aires hay 22 grupos con abandono alto y el modelo detecta 1, pero marca otros 17 que el registro da como bajos: por el perfil de sus estudiantes, esos grupos «deberían» tener más abandono del que figura. En Santa Fe pasa al revés: 34 grupos con abandono alto y el modelo detecta 7. O cada provincia registra distinto, o hay algo propio de cada una que Aprender no ve. Con estos datos no lo podemos distinguir. **Que el registro cambie entre provincias es una hipótesis nuestra.** El documento oficial del Relevamiento sostiene lo contrario: el sistema «garantiza la homogeneidad y comparabilidad de los datos en todo el ámbito nacional» (DIEE, documento metodológico de las bases del Relevamiento Anual), y no encontramos ningún documento oficial que advierta diferencias. Nos apoyamos en la dispersión de la tasa y en la caída de Buenos Aires, que con la secundaria entera pasa de 2,97% en 2011 a 0,30% en 2024. Por eso proponemos revisarlo con ellas antes de comparar provincias.

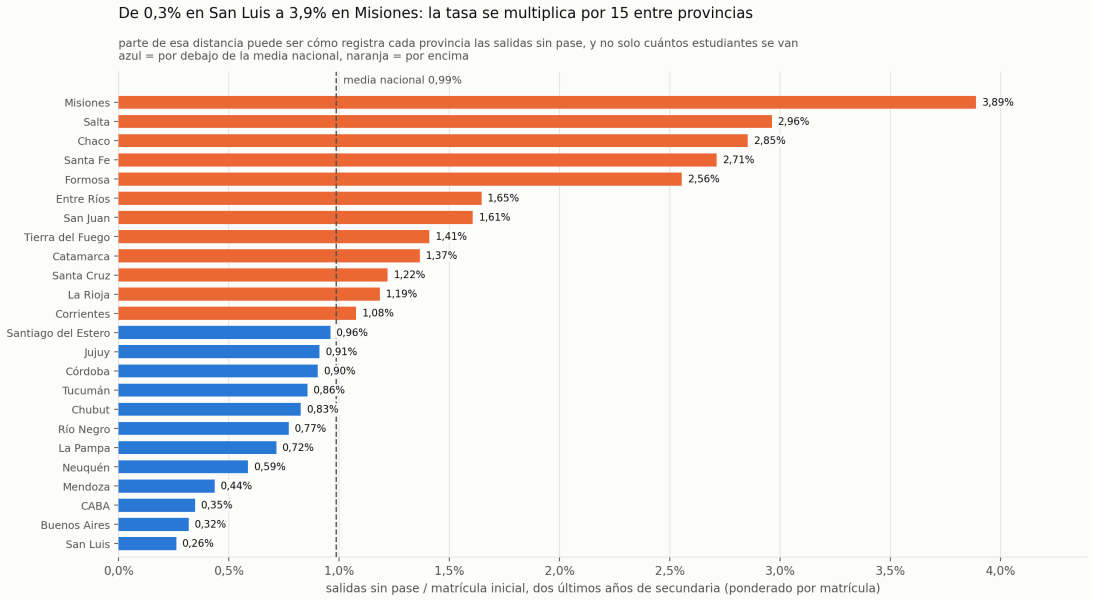


Figura 2. Tasa de abandono registrada en los dos últimos años de la secundaria, por provincia. Naranja, por encima de la media nacional; azul, por debajo.

8. Los grupos que el modelo no marca

La mentora propuso una segunda mirada sobre los grupos que el modelo no marca como abandono alto. Los agrupamos por seis rasgos parecidos (sin usar el abandono para armarlos) y aparecen 4 perfiles. El privado urbano casi no tiene abandono. Los otros tres (estatal urbano, rural estatal y rural más vulnerable) tienen tasas parecidas entre sí, y entre todos los no marcados quedan 156 grupos con abandono alto que el modelo no vio. El perfil que más concentra es el estatal urbano.

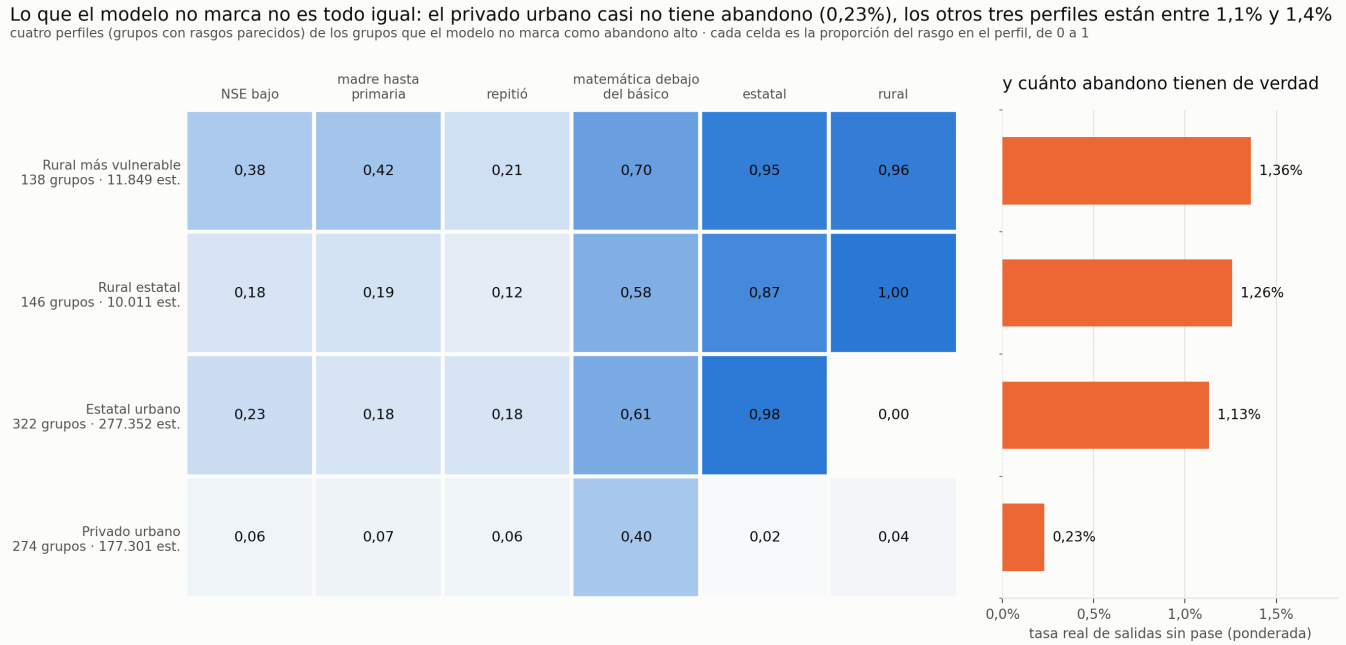


Figura 3. Los cuatro perfiles de grupos que el modelo no marca. Cada celda es la proporción del rasgo en el perfil (de 0 a 1); a la derecha, cuánto abandono registran de verdad.

9. Cómo lo analizamos

Dos fuentes que miran cosas distintas. Aprender lo responde el estudiante el día de la prueba: cuenta cómo le va y cómo vive, pero no puede ver el abandono, porque el que ya se fue no rinde. El Relevamiento Anual lo completa cada escuela: cuenta quién se fue, pero no sabe nada de los hogares. Las unimos por grupo de escuelas, con los archivos 2024. **Qué predecimos:** la tasa de abandono es la cantidad de salidas sin pase de los dos últimos años (salido sin pase es «el que se va de la escuela a la que asistía, sin inscripción (o pase) en otra escuela», DiNIECE y RedFIE) dividida por los inscriptos de esos años (la misma población que evalúa Aprender), y un grupo tiene abandono alto si su tasa está en el cuarto más alto del país (1,74% o más; son 294 grupos). **Contra qué nos medimos:** las tres reglas simples de la sección 5. **Sin mirar la respuesta:** no usamos nada que se conozca después del resultado (los no promovidos, los pases ni los egresados del mismo año), y cada grupo lo evaluó un modelo que no lo había visto. **Lo que no aportó:** sumar dos indicadores de la Encuesta Permanente de Hogares por provincia, como pidió la mentora, deja el resultado en 0,751: lo que la encuesta mide de cada provincia ya lo dice Aprender.

10. Limitaciones

- **Grupos, no personas.** Nada de esto permite decir algo de un estudiante concreto.
- **El abandono registrado no es el abandono real.** Un cero no se distingue de «no se registró», y la tasa cambia mucho entre provincias; que sea por cómo registra cada una es una hipótesis nuestra (sección 7).
- **Lo que el registro no cuenta y lo que cuenta de más.** Quien se va entre diciembre y marzo, después del último día de clase, no figura como salida sin pase (cuadernillo del Relevamiento Anual 2025), y la categoría incluye pases no tramitados: estudiantes que siguen en otra escuela sin haber hecho el trámite (Dirección General de Cultura y Educación de Buenos Aires, 2022).
- **Desfase de un año, documentado.** El Relevamiento informa las salidas del ciclo anterior (cuadernillo del Relevamiento Anual 2025): el archivo 2024 trae el ciclo 2023, y Aprender es de octubre de 2024.
- **Lo que medimos es inestable.** De los grupos con abandono alto en 2024, solo el 53% ya lo tenía el año anterior: en grupos chicos, una sola salida mueve la tasa entera.
- **El corte del cuarto superior es nuestro.** Lo probamos con el tercio y el quinto superior y aguanta (sección 5).
- **Aprender solo ve a quien fue a rendir**, y eso subestima justo a los grupos con más abandono.

11. Qué sigue

- Sumar el Relevamiento 2025, que trae el abandono del ciclo 2024, el mismo de Aprender.
- Incorporar el abandono interanual oficial (quién no se reinscribe al año siguiente), que capta lo que las salidas sin pase no ven.
- Revisar con las provincias cómo registran las salidas sin pase, empezando por Buenos Aires y Santa Fe, antes de comparar provincias entre sí.
- Predecir el año siguiente con los datos del anterior, que es lo que haría un sistema de alerta temprana de verdad.

Código, datos y documentación: https://github.com/IVillanueva770/factor-d10s-m01

Notebook en Colab: PENDIENTE

Fuentes citadas, con la cita textual y el enlace: entregas/03-machine-learning/FUENTES-TP3.md en el repositorio. Ahí también separamos lo que ya se sabía de lo que es hallazgo nuestro.

Nota para lectores técnicos: la escala de 0,5 a 1 es el área bajo la curva ROC (ROC-AUC); los dos modelos son una regresión logística y un boosting de árboles (el que combina provincia y perfil suma una variable indicadora por provincia); los perfiles salen de k-means sobre seis rasgos; la evaluación es una cross-validation de cinco particiones, estratificada y también agrupada por provincia, sin leakage de variables posteriores al resultado.