

EL FACTOR D10S

Etapas 3 · Machine Learning

Del análisis al modelo: ahora toca intentar predecir

En las etapas anteriores exploraron los datos de Pruebas Aprender y de la EPH, conocieron sus variables, detectaron problemas de calidad y comenzaron a entender qué información puede aportar cada fuente.

Hasta acá estuvimos tratando de conocer y entender los datos. Ahora el desafío cambia, vamos a ponerlos a trabajar. Pero hay una condición importante: en un proyecto real no alcanza con entrenar un algoritmo y mostrar un accuracy. El objetivo de esta etapa es que puedan recorrer el proceso completo: definir el problema, decidir qué quieren predecir, preparar los datos, probar modelos y evaluar si los resultados tienen sentido.

Regla de oro: el modelo no empieza con `RandomForestClassifier()`. Empieza preguntándonos qué estamos intentando predecir y si nuestros datos realmente permiten hacerlo.

1. El desafío

La pregunta de partida del proyecto es el abandono escolar. Sin embargo, antes de convertir esa idea en un problema de Machine Learning, deberán analizar cuidadosamente cómo está representada la información en los datos.

Un punto central del proyecto es la granularidad: una fila del dataset no necesariamente representa a un estudiante individual y las dos fuentes no cuentan con una llave que permita vincular directamente a una persona de Aprender con una persona de EPH.

Por lo tanto, no den por supuesto que pueden predecir el abandono de un estudiante individual. Primero deberán determinar qué unidad de análisis pueden sostener con evidencia y qué tipo de predicción es razonable hacer.

2. Antes de modelar: definan el problema

Si todavía no lo han hecho, antes de elegir algoritmo, respondan en su notebook (con sus propias palabras) estas preguntas:

- ¿Qué representa una fila? ¿Una persona, un hogar, una observación muestral, una escuela, un grupo o alguna otra unidad?
- ¿Qué fenómeno queremos predecir? Eviten quedarse solamente con la frase “abandono escolar”. Intenten definir qué significa operacionalmente.
- ¿Existe una variable que observe realmente ese fenómeno? Si no existe, ¿puede construirse mediante una regla válida y justificable?
- ¿Qué información estaba disponible antes del resultado? No utilicen como predictor información que solamente podría conocerse después.
- ¿Qué podemos afirmar y qué no podemos afirmar? Esta parte también forma parte del trabajo.

3. Definición del target: sin vender humo

Si existe una variable que representa de manera razonable el resultado de interés, utilícela y documenten por qué.

Un target de Machine Learning no es simplemente “lo que queremos saber”. Es aquello que nuestros datos permiten observar y definir de manera reproducible.

Si necesitan construir el target, expliquen claramente la regla utilizada. Por ejemplo: “Definimos abandono como...”. La regla debe poder ser aplicada de la misma manera a todas las observaciones.

Si los datos no permiten observar abandono individual, no inventen una variable para forzar el problema. En ese caso, reformulen la pregunta hacia una unidad de análisis que los datos sí permitan sostener, o documenten por qué el problema original no puede resolverse con las fuentes disponibles.

Situación	Qué hacer
Existe una variable observable relacionada con el resultado.	Usarla como target y explicar qué representa.
Puede construirse mediante una regla clara y defendible.	Construirla, documentar la regla y revisar su distribución.
No puede observarse ni construirse sin asumir información no disponible.	No forzar un target. Reformular el problema o documentar la limitación.

4. Preparación de los datos

Partan del dataset que obtuvieron luego del EDA. No hace falta repetir todo el análisis exploratorio: aprovechen lo que ya descubrieron.

- Revisen nuevamente tipos de datos, valores faltantes y categorías.
- Decidan qué variables conservar, transformar o descartar y expliquen brevemente las decisiones importantes.
- Realicen las transformaciones necesarias para que las variables puedan utilizarse en los modelos.
- Eviten incluir variables que filtren información del target o que solo estén disponibles después del evento que quieren predecir.
- Si realizan balanceo, imputación, escalado u otra transformación, piensen en qué momento del pipeline debe hacerse para evitar leakage.

5. Construyan un baseline

Antes de probar modelos sofisticados, construyan una referencia sencilla. El baseline les permitirá responder una pregunta básica:

¿Mi modelo realmente está aprendiendo algo útil o solamente estoy haciendo más complicado un problema que una regla simple ya resuelve?”

El baseline puede ser un modelo simple y fácil de interpretar. Luego podrán compararlo con otras alternativas.

6. Experimenten con modelos

A partir del baseline, prueben los modelos que consideren adecuados para el problema definido. No se busca que utilicen muchos algoritmos por cantidad. Se busca que puedan explicar por qué probaron cada uno y qué aprendieron al compararlos.

- Pueden probar distintos modelos de clasificación o regresión, según el target que hayan definido.
- Pueden ajustar hiperparámetros si tiene sentido.
- Pueden experimentar con distintas representaciones de las variables.
- Pueden comparar resultados y analizar errores.
- Si una técnica no funciona, también es un resultado. Expliquen qué probaron y qué observaron.

7. Evaluación: no se enamoren del accuracy

La métrica debe estar relacionada con el problema y con el comportamiento de los datos. No alcanza con informar una única métrica.

- Clasificación: consideren, según corresponda, matriz de confusión, precision, recall, F1, ROC-AUC y/o PR-AUC.
- Desbalance: revisen la distribución de las clases. Un accuracy alto puede ser engañoso.
- Errores: analicen qué tipo de observaciones el modelo clasifica mal.
- Generalización: separen entrenamiento y evaluación correctamente y justifiquen la estrategia utilizada.

8. Interpretación: ¿qué aprendimos?

Esta parte es tan importante como las métricas. Intenten traducir los resultados a lenguaje de negocio/investigación.

- ¿Qué variables parecen aportar información al modelo?
- ¿El modelo encuentra patrones razonables o aparecen resultados extraños?
- ¿Qué errores son especialmente relevantes?
- ¿Qué conclusiones pueden sostener con los datos?
- ¿Qué conclusiones no pueden sostener?

Importante: que una variable sea útil para predecir no significa automáticamente que sea la causa del fenómeno. Predicción y causalidad son preguntas diferentes.

9. ¿Qué se espera como entrega?

No buscamos un notebook de 80 celdas donde se muestre que entrenaron 14 modelos. Buscamos un mini proyecto de Machine Learning (MVP) defendible, similar a lo que podrían presentar en un equipo de datos.

Entregable	Qué debería verse
1. Problema	Pregunta de negocio/investigación y unidad de análisis.
2. Target	Qué predicen, cómo se definió y por qué es válido para los datos disponibles.
3. Datos	Variables utilizadas y decisiones importantes de preparación.
4. Baseline	Modelo/regla de referencia y resultado.
5. Modelos	Al menos una alternativa al baseline, con justificación.
6. Evaluación	Métricas adecuadas, comparación y análisis de errores.
7. Interpretación	Qué patrones encontraron y cómo los interpretarían.

8. Limitaciones	Qué problemas de datos, granularidad, representatividad o target afectan las conclusiones.
9. Próximos pasos	Qué harían si tuvieran más datos, más tiempo o acceso a otra fuente.

10. Libertad para experimentar

A partir de esta simil guía, el camino es de ustedes. Pueden probar estrategias distintas, comparar resultados, volver atrás y reformular.

- No hay un único modelo correcto.
- No tienen que utilizar todas las técnicas vistas en clase.
- Pueden justificar una decisión diferente a la sugerida en clase si los datos la respaldan.
- Un experimento que no mejora el modelo también puede aportar conocimiento.
- Si descubren que la pregunta original no puede responderse correctamente con estos datos, decirlo y demostrar por qué también es un resultado válido.

11. Checklist antes de entregar

- Sé qué representa una fila de mi dataset.
- Puedo explicar cuál es mi unidad de análisis.
- Puedo explicar qué estoy prediciendo.
- Mi target está observado o construido mediante una regla explícita.
- No estoy inventando información que los datos no contienen.
- Revisé posibles problemas de data leakage.
- Separé correctamente entrenamiento y evaluación.
- Tengo un baseline.
- Elegí métricas adecuadas al problema.
- Analicé errores, no solamente métricas.
- Puedo explicar qué aprendí del modelo.
- Dejé claras las limitaciones.

12. La pregunta que debería quedar abierta al final

Después de todo este proceso, ¿qué podemos afirmar con nuestros datos...y qué sería inventar una historia que los datos no pueden sostener?"

Y por ultimo, les remarco lo mismo que en entregables anteriores, el objetivo no es construir “el modelo perfecto”, de hecho no existe un modelo mágico, existe un problema, unos datos y una serie de decisiones que ustedes tienen que poder defender. Por eso, el objetivo siempre va a ser aprender a tomar decisiones de datos de manera razonada, reproducible y honesta.